Análisis de Modelos Transformers aplicados a la predicción de activos de Bolsa de Valores

1st Manuel Eduardo Zeze Charaja Quispe
Ciencia de la Computación
Universidad Católica San Pablo
Arequipa, Peru
manuel.charaja@ucsp.edu.pe

***Resumen*—Con el emerger del aprendizaje profundo y la inteligencia artificial, el análisis financiero ha tenido avances sustanciales en cuanto a predicciones mediante diversos métodos. Las arquitecturas *Transformer* en específico han demostrado ser una buena solución para analizar relaciones entre activos o para crear predicciones. En este Proyecto se va a revisar la eficiencia de diferentes modelos *Transformer* en tareas de predicción en el mercado de valores así como las diversas técnicas usadas en dicho proceso.**

I. Introduction

El objetivo de crear predicciones precisas y entender el estado del mercado para predecir los valores de los activos es algo tan antiguo como la existencia del mercado en si mismo. Es por ello que son un tema que posee extensa investigación para la detección de patrones mediante técnicas tradicionales para predicción mediante el uso de series temporales. Algunas de estas técnicas a mencionar son los métodos ARIMA [1] y GARCH [2]. Sin embargo, en un mundo manejado de manera multifactorial, estos métodos se ven opacados por la misma naturaleza del mercado, el cual se ve afectado por cuestiones no cuantificables en dichos métodos, siendo mas específico la falta de adaptabilidad eficaz a nuevos entornos y/o tendencias [3].

La vasta mayoria de los *Transformers* hacen uso de las series temporales para construir las predicciones, sin embargo, dentro del amplio espectro de diferentes modelos *Transformer*, se puede apreciar que los modelos mas basicos pertenecen a la categoria de univariados [4].

En este proyecto, se va a buscar analizar los diferentes tipos de *Transformer* para contrastar su eficiencia para la prediccion de activos en el mundo bursatil.

II. Marco Teórico

La predicción en la bolsa y que conlleva la creación de una predicción es un tema complejo de estudio para analistas e inversores [3]. Modelos tradicionales con base matemática han sido desarrollados, ademas de modelos de redes neuronales con el mismo objetivo, con sus respectivas ventajas y dificultades. A continuación se presentara una definición para cada uno de los diversos modelos, para el modelo *Transformer* original, así como definiciones básicas de los modelos de *Transformer* adaptados a un entorno bursátil, también se definirán las métricas usadas como referencia para la comparación entre los diversos modelos.

II-A. Predicción en la bolsa

La predicción en la bolsa, también conocida como predicción bursátil, tiene como objetivo estimar el valor futuro de activos financieros (acciones, índices, etc) utilizando datos históricos de precios, volumen, etc. Estos datos constituyen lo que se conoce como una Serie Temporal, o una secuencia de observaciones ordenadas en el tiempo [4]. Es en base a estos datos que se construyen predicciones de forma tradicional mediante el uso de métodos estadísticos, Estos métodos han sido ampliamente usados a lo largo de las ultimas décadas. No obstante presentan inconvenientes ante factores psicológicos o sociales que también influyen en el mercado y que los métodos matemáticos de predicción tradicionales no son capaces de prever o cuantificar dentro de sus esquemas.

II-B. Series Temporales

Las series temporales son normalmente un conjunto de variables aleatorias observadas y almacenadas de manera secuencial sobre el tiempo, esto con el propósito de detección de anomalías, eventos o para la construcción de predicciones en varios campos de estudio [4].

Se puede clasificar las Series Temporales de 2 formas:

- Series Temporales Estándar: Es definida como una secuencia de puntos de de datos ordenados en un tiempo, pueden ser univariadas o multivariadas.
- Series Temporales Espaciales: Se refiere a la secuencia de puntos de datos con dimensiones tanto espaciales como temporales, este tipo de series temporales pueden ser subdivididas en 2 subtipos mas: Grafos Espacio Temporales y Rastros Espacio Temporales

En el Survey de Liang et al. [5]. se menciona también el uso de Series Temporales como Trayectoria y como secuencia de eventos, sin embargo se menciona que la mayoría de estudios en esa categoría se enfocan en datos de trayectoria y posee menos modelos mencionados. En la Figura 1 se pueden apreciar ejemplos gráficos proporcionados por Liang et al para la clasificación mencionada.

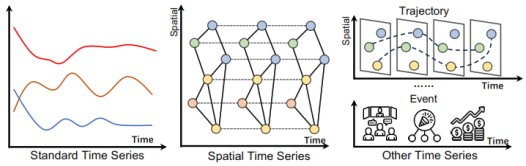

Figura 1. Ejemplos de una Serie Temporal, a la derecha una Serie Temporal Estandar, en medio, una Serie Temporal Espacial, al lado derecho se aprecian 2 ejemplos que de arriba a abajo corresponden a las Series Temporales de Trayectoria y de Secuencia de Everntos respectivamente, propuestos por Liang et al, 2024

II-C. Modelos Clásicos de Predicción Financiera

Los métodos estadísticos tradicionales, o también llamados modelos clásicos de predicción financiera, son modelos que por medio de datos históricos y la identificación de patrones permiten crear predicciones sobre el comportamiento de una acción, estos modelos se clasifican en modelos de regresión y Análisis de series temporales, el primer conjunto de modelos analiza datos históricos y hace uso de variables independientes para crear predicciones de mercado o clasificar el rendimiento de las acciones en categorías. Por otro lado, los modelos de análisis de series temporales usan los datos históricos para identificar tendencias, basados en los cuales crea futuras predicciones, por lo que el reconocimiento de patrones juega un rol crucial" [6]. Dos de los modelos mas conocidos dentro del análisis de series temporales son los modelos ARIMA y GARCH .

Generalized Auto Regressive Conditional Heteroskedasticity (GARCH) [2] busca extender el modelo anteriormente mencionado, esto con el fin de capturar los cambios en la varianza del error a lo largo del tiempo, algo que también se le conoce como volatilidad condicional. Aquí se presenta la ecuación base del modelo:

$$\sigma_t^2 = \alpha_0 + \sum_{i=1}^{p} \alpha_i \varepsilon_{t-i}^2 + \sum_{j=1}^{q} \beta_j \sigma_{t-j}^2 \tag{1}$$

Donde:

- σ_t^2 representa la varianza condicional del error en el tiempo
- α_0 es el término constante que determina el nivel base de la varianza
- ε_{t-i}^2 son los errores pasados o innovaciones anteriores, que reflejan los choques recientes en la volatilidad.
- α_i son los coeficientes ARCH
- σ_{t-j}^2 son las varianzas condicionales pasadas.
- β_j son los coeficientes GARCH.
- p indica el orden del componente ARCH.
- q indica el orden del componente GARCH.

Estos enfoques son eficientes en entornos generales, pero, su mayor dificultad aparece ante comportamientos de tipo no lineal, así como a cambios estructurales en los mismos mercados para los cuales fueron diseñados, lo que los termina limitando a mercados en especifico [2].

II-D. Deep Learning

Deep Learning (DL) se define como un subset dentro de *Machine Learning* (ML) que usa redes neuronales con muchas capas para modelar patrones complejos en los datos. En cuanto a inversiones se refiere, técnicas de *Deep Learning* son usadas en predicción de activos en bolsa, análisis de datos no lineales, etc. Algunas de las técnicas presentes en *Deep-Learning* son ampliamente usadas en el mundo financiero, como por ejemplo las Redes Neuronales Recurrentes *Recurrent Neural Networks* (RNN) son un tipo de red neuronal, diseñada para procesar datos secuenciales manteniendo una memoria de entradas previas, las Redes Neuronales Convolucionales *Convolutional Neural Network* (CNN) son arquitecturas ampliamente usadas para procesar datos de tipo "mallaçomo imágenes y series temporales, *Long Short Term Memory* (LSTM) es una red RNN especializada diseñada para capturar dependencias de largo plazo en datos secuenciales, todo esto mientras evade el *gradient-vanishing-problem* o por ultimo *Gated Recurrent Unit* o GRU, las cuales son una versión simplificada de el modelo anteriormente mencionado que procesa datos secuenciales al mismo tiempo que logra reducir la complejidad computacional [6].

Estas técnicas tienden a superar a los métodos tradicionales en cuanto a precisión, sin embargo estas técnicas son susceptibles a la calidad de los datos con los que son entrenados o tienen problemas con la volatilidad del mercado.

II-E. Transformer

El modelo *Transformer*, es una arquitectura de aprendizaje profundo cuyo diseño original buscaba lograr traducciones automáticas. Consiste en reemplazar las estructuras secuenciales recurrentes por un mecanismo de auto-atención que permite procesar de forma paralela todos los elementos de una secuencia y capturar relaciones de dependencia a largo plazo que puedan existir entre ellos [7].

Cabe recalcar que los *Transformers* no dependen del orden de entrada explicito, sino que incorpora información posicional a través de vectores de codificación, es gracias a eso y a la gran flexibilidad y esca labilidad que es una gran alternativa para modelos aplicados a series temporales financieras. La arquitectura original del modelo *Transformer* se pude ver en la Figura I

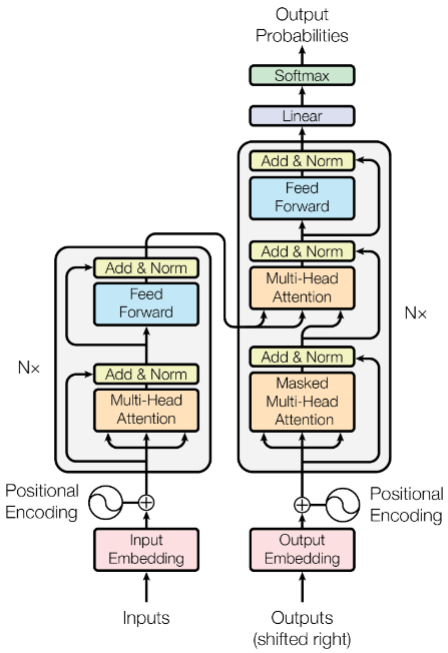

Figura 2. Arquitectura de un Transformer propuesta por Vaswani et al, 2017

III. Estado del Arte

Existe una extensa cantidad de artículos que proponen modelos *Transformers* enfocados en predicción bursátil. A pesar de ello, la cantidad de *Surveys* que buscan analizarlos o contrastarlos es bastante limitada (la mayoría tiene un enfoque a series temporales en general, incluyendo datos del clima o de servicios []). Sin embargo, a pesar de ello, existen algunos *Surveys* de alta relevancia para este proyecto. Uno de los *Surveys* mas relevantes dentro del estado del arte para el tema vendría a ser el *Survey* de Wen et al. [8], en el cual se propone la clasificación de *Transformers* en tareas diversas como *forecasting*, detección de anomalías, generación, etc. Cabe recalcar que también se identificaron problemas en contextos especializados. Otro *Survey* que aborda el tema es el *Survey* de Su et al. [4] en el cual se presenta una revisión de forma sistemática para los modelos *Transformer* aplicados al *Long Term Series Forecasting* (LTSF) examinando las principales modificaciones de la arquitectura del modelo original, también identificando diversos problemas como la dependencia de enormes volúmenes de datos o el alto costo computacional. Sin embargo, se puede extrapolar de ellos que existe una brecha durante la transferencia a contextos financieros, esto por la alta volatilidad, cambios de régimen o señales ruidosas, destaca también la dependencia de datos heterogéneos. Cabe recalcar también que ninguno de los 2 *Surveys* presentados están completamente centrado en finanzas, pero analizan su posibilidad para varios ámbitos, incluyendo la predicción de mercado, no unicamente para predicción bursátil. En este proyecto se va a buscar ampliar dichas revisiones con un enfoque en entornos bursátiles, analizando las diversas adaptaciones, metodologías y desempeño para crear una clasificación.

IV. Arquitecturas *Transformer* para predicción en bolsa

La arquitectura del modelo *Transformer* original propuesta por Vaswani et al [7] fue adaptada para su uso en tareas de predicción básicas, con resultados deplorables dada la poca adaptabilidad del modelo a contextos volátiles y no estables []. Sin embargo a partir de dichos primeras fases, la cantidad de modelos *Transformer* enfocados en la predicción de activos se diversifico, con algunos modelos especializándose en mercados específicos, buscando la relación y el efecto que tienen diferentes activos entre si e incluso integrando opiniones o sentimiento de mercado en mercados específicos. Sin embargo todo esto requirió la modificación de dicha arquitectura original en mayor o menor medida por cada modelo, siendo en algunos casos necesario la implementación de modelos híbridos o la eliminación de mecanismos inherentes a la arquitectura original para la aplicación de dichas mejoras [7] [9] [10].

Kim et al. [10] proponen el modelo CATS (cuyas siglas significan *Cross-Attention-only Time Series Transformer*) buscando eliminar completamente la *self-attention* tradicional y emplear unicamente mecanismos de *Cross-Attention* para mejorar la predicción de series temporales especialmente en horizontes largos. El modelo introduce tres innovaciones principales: Consultas Dependientes del Horizonte, en las cuales cada paso futuro se representa mediante una consulta que atiende directamente al historial, *Parameter Sharing Across Horizones*, el cual reutiliza las mismas capas de embedding, atención y proyección para todos los horizontes, reduciendo sustancialmente el numero de parámetros y *Query-Adaptative Masking* el cual genera mascarillas adaptativas para evitar que todos los horizontes produzcan salidas similares. Se hicieron evaluaciones extensas sobre los *datasets* Electricity, Weather, Traffic, ETTh1, ETTh2, ETTm1, ETTm2 y M4, en los cuales CATS supero consistentemente a modelos como PatchTST, TimeMixer y DLinear en MSE y MAE, manteniendo un numero de parámetros casi constante, por lo que se puede definir que entre sus fortalezas incluyen una alta eficiencia computacional. En la figura 3 se presenta la arquitectura para el modelo CATS propuesta por Kim et al.

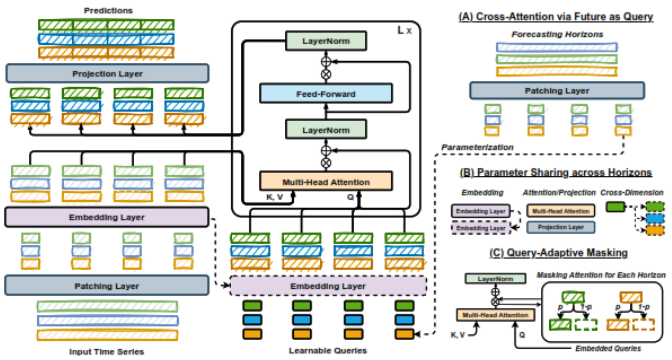

Figura 3. Arquitectura CATS propuesta por Kim et al.

Kabir et al. [9] proponen el modelo *LSTM–mTrans–MLP* el cual es un enfoque híbrido diseñado para mejorar la predicción de series temporales financieras mediante la integración de tres componentes complementarios. Se empieza con un bloque LSTM captura dependencias de corto y largo plazo con mayor tolerancia a problemas en los *datasets*, generando un vector de características robusto; este se introduce en un *Transformer* que emplea *multi-head attention*, conexiones residuales y una arquitectura simplificada sin *embeddings* ni decodificador, lo que le permite concentrar la atención en las secciones más relevantes de la secuencia y mejorar la contextualización temporal, al final una red perceptron multicapa aprende relaciones no lineales complejas a partir de las representaciones atencionales, produciendo la estimación final del precio futuro.

Las pruebas se realizaron en múltiples activos financieros (Bitcoin, China Unicom, CSI 300, CSI 100, Shanghai Composite Index, Amazon y Google) manteniendo consistencia bajo condiciones de alta volatilidad como la pandemia de COVID-19 superando a modelos estadísticos, redes profundas convencionales en métricas como MSE, RMSE, MAE y MAPE, por lo que sus fortalezas incluyen robustez en mercados divergentes, arquitectura ligera, bajo número de parámetros y excelente capacidad de generalización. No obstante, depende unicamente de la calidad de los datos históricos. En la figura 11 se presenta la arquitectura modificada propuesta por Kabir et al para el modelo LTSM-mTrans-MLP. La arquitectura del modelo *Transformer* usada en este modelo se puede apreciar en la figura 4.

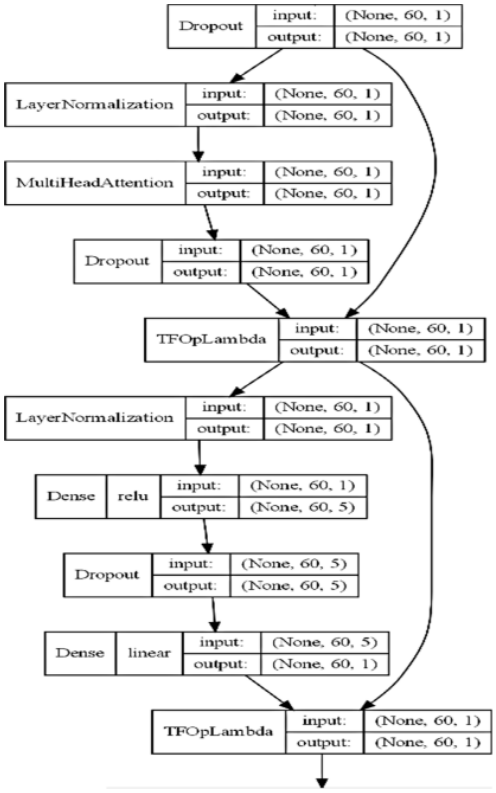

Figura 4. Arquitectura LSTMmTransMLP propuesta por Kabir et al.

V. Conclusiones

El uso de arquitecturas *Transformer* para la predicción de activos, las cuales usan en su mayoría Series Temporales para la construcción de dichas predicciones, ha demostrado un alto nivel de eficiencia y adaptabilidad en el ultimo lustro, Cabe reclacar los diversos modelos que han surgido en base a los primeros intentos mediante el uso de la arquitectura propuesta originalmente por Vaswani et al. hasta los diversos modelos especializados que se poseen y se usan de forma comercial.

Debe mencionarse también su integración en modelos con mayor alcance como son los *Foundation Models for Time Series* así como en otras arquitecturas que dependen de la arquitectura *Transformer* o sus derivaciones para la correcta construcción de predicción en la bolsa de valores. Sin embargo estos modelos presentan una complejidad mayor al uso de arquitecturas *Transformer* como parte principal de la arquitectura pero al igual que las muchas derivaciones, es solo un paso mas en la evolución del deseo humano de conocer el futuro y desde el presente hacerlo parte de si.

References

Referencias

[1] G. E. Box, G. M. Jenkins, G. C. Reinsel, and G. M. Ljung, *Time series analysis: forecasting and control (Revised)*. John Wiley & Sons, 2015.

[2] T. Bollerslev, "Generalized autoregressive conditional heteroskedasticity," *Journal of econometrics*, vol. 31, no. 3, pp. 307–327, 1986.

[3] O. Shobayo, S. Adeyemi-Longe, O. Popoola, and O. Okoyeigbo, "A comparative analysis of machine learning and deep learning techniques for accurate market price forecasting," *Analytics*, vol. 4, no. 1, p. 5, 2025.

[4] L. Su, X. Zuo, R. Li, X. Wang, H. Zhao, and B. Huang, "A systematic review for transformer-based long-term series forecasting," *Artificial Intelligence Review*, vol. 58, no. 3, p. 80, 2025.

[5] Y. Liang, H. Wen, Y. Nie, Y. Jiang, M. Jin, D. Song, S. Pan, and Q. Wen, "Foundation models for time series analysis: A tutorial and survey," in *Proceedings of the 30th ACM SIGKDD conference on knowledge discovery and data mining*, 2024, pp. 6555–6565.

[6] M. Saberironaghi, J. Ren, and A. Saberironaghi, "Stock market prediction using machine learning and deep learning techniques: A review," *AppliedMath*, vol. 5, no. 3, p. 76, 2025.

[7] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin, "Attention is all you need," *Advances in neural information processing systems*, vol. 30, 2017.

[8] Q. Wen, T. Zhou, C. Zhang, W. Chen, Z. Ma, J. Yan, and L. Sun, "Transformers in time series: A survey," *arXiv preprint arXiv:2202.07125*, 2022.

[9] M. R. Kabir, D. Bhadra, M. Ridoy, and M. Milanova, "Lstm–transformer-based robust hybrid deep learning model for financial time series forecasting," *Sci*, vol. 7, no. 1, p. 7, 2025.

[10] D. Kim, J. Park, J. Lee, and H. Kim, "Are self-attentions effective for time series forecasting?" *Advances in Neural Information Processing Systems*, vol. 37, pp. 114 180–114 209, 2024.

[11] Z. Tao, W. Wu, and J. Wang, "Series decomposition transformer with period-correlation for stock market index prediction," *Expert Systems with Applications*, vol. 237, p. 121424, 2024.

[12] H. Zhou, S. Zhang, J. Peng, S. Zhang, J. Li, H. Xiong, and W. Zhang, "Informer: Beyond efficient transformer for long sequence time-series forecasting," in *Proceedings of the AAAI conference on artificial intelligence*, vol. 35, no. 12, 2021, pp. 11 106–11 115.