

Análisis de Modelos Transformers aplicados a la predicción de activos de Bolsa de Valores basados en Series Temporales

1st Manuel Eduardo Zeze Charaja Quispe
Ciencia de la Computación
Universidad Católica San Pablo
Arequipa, Peru
manuel.charaja@ucsp.edu.pe

2st Yván Jesús Túpac Valdivia
Ciencia de la Computación
Universidad Católica San Pablo
Arequipa, Peru
ytupac@ucsp.edu.pe

Resumen—Con el emerger del aprendizaje profundo y la inteligencia artificial, el análisis financiero ha tenido avances sustanciales en cuanto a predicciones mediante diversos métodos y arquitecturas. Las arquitecturas *Transformer* en específico han demostrado ser idóneas para analizar relaciones entre activos o para crear predicciones en base a series temporales. Sin embargo poseen poca generalidad O gran coste computacional. El objetivo de este estudio es comparar el rendimiento de 2 arquitecturas *Transformer* para tareas de predicción bursátil: *Cross Attention Time Series Transformer* (CATS) y *Fredformer*, evaluando como cada uno maneja los desafíos mencionados.

Index Terms—Stock Market, *Transformer*, CATS, *Fredformer*, Prediction, Deep Learning.

I. INTRODUCCIÓN

El uso de técnicas para la predicción de valores en el mercado puede trazarse hasta los orígenes del mercado en si mismo, conocer los valores de los activos es algo esencial para la construcción de un buen portafolio. Es por ello que es un tema que posee extensa investigación para la detección de patrones mediante técnicas diversas, algunas de las técnicas de mayor uso vienen a ser las técnicas tradicionales mediante el uso de series temporales. Algunas de estas técnicas a mencionar son los métodos ARIMA [1] y GARCH [2]. Sin embargo, en un mundo manejado de manera multifactorial, estos métodos se ven opacados por la misma naturaleza del mercado, el cual se ve afectado por cuestiones no cuantificables en dichos métodos, siendo mas específico la falta de adaptabilidad eficaz a nuevos entornos y/o tendencias [3].

El uso de *Machine Learning* y *Deep Learning* en predicciones generales se ha consolidado como una mejora para dichas predicciones, lo que dio a pie a nuevas técnicas enfocadas para dichos fines (mecanismos como las redes neuronales artificiales (ANN), redes neuronales recurrentes (RNN) o las redes neuronales convolucionales (CNN)), no obstante dichas técnicas no están pensadas para estas tareas y presentan entrenamiento complejo o no tienen la capacidad de capturar relaciones largas de tiempo, por otro lado, las arquitecturas *Transformer*, innovación dentro del campo del *Deep Learning*, logro saltar esa barrera y, aunque originalmente no con la predicción de series temporales como objetivo, ha demostrado

su enorme potencial para la captura de patrones en largos espacios de tiempo así como la creación de predicciones basados en esos datos, aun así las arquitecturas *Transformer* presentan una mayor complejidad computacional que las técnicas anteriormente mencionadas, además de una clara especialización para mercados en específico, esto dado más por la misma naturaleza del mercado.

I-A. Predicción en la bolsa

La predicción en la bolsa, también conocida como predicción bursátil, tiene como objetivo estimar el valor futuro de activos financieros (acciones, índices, etc) utilizando datos históricos de precios, volumen, etc. Estos datos constituyen lo que se conoce como una Serie Temporal, o una secuencia de observaciones ordenadas en el tiempo [4]. Es en base a estos datos que se construyen predicciones de forma tradicional mediante el uso de métodos estadísticos. Estos métodos han sido ampliamente usados a lo largo de las últimas décadas. No obstante presentan inconvenientes ante factores psicológicos o sociales que también influyen en el mercado y que los métodos matemáticos de predicción tradicionales no son capaces de prever o cuantificar dentro de sus esquemas.

I-B. Series Temporales

Las series temporales son normalmente un conjunto de variables aleatorias observadas y almacenadas de manera secuencial sobre el tiempo, esto con el propósito de detección de anomalías, eventos o para la construcción de predicciones en varios campos de estudio [4].

Se puede clasificar las Series Temporales de 2 formas:

- Series Temporales Estándar: Es definida como una secuencia de puntos de datos ordenados en un tiempo, pueden ser univariadas o multivariadas.
- Series Temporales Espaciales: Se refiere a la secuencia de puntos de datos con dimensiones tanto espaciales como temporales, este tipo de series temporales pueden

ser subdivididas en 2 subtipos mas: Grafos Espacio Temporales y Rastros Espacio Temporales

En el Survey de Liang et al. [5]. se menciona también el uso de Series Temporales como Trayectoria y como secuencia de eventos, sin embargo se menciona que la mayoría de estudios en esa categoría se enfocan en datos de trayectoria y posee menos modelos mencionados. En la Figura 1 se pueden apreciar ejemplos gráficos proporcionados por Liang et al para la clasificación mencionada.




Figura 1: Ejemplos de una Serie Temporal, a la derecha una Serie Temporal Estándar, en medio, una Serie Temporal Espacial, al lado derecho se aprecian 2 ejemplos que de arriba a abajo corresponden a las Series Temporales de Trayectoria y de Secuencia de Eventos respectivamente, propuestos por Liang et al, 2024 [5]

I-C. Modelos Clásicos de Predicción Financiera

Los métodos estadísticos tradicionales, o también llamados modelos clásicos de predicción financiera, son modelos que por medio de datos históricos y la identificación de patrones permiten crear predicciones sobre el comportamiento de una acción, estos modelos se clasifican en modelos de regresión y análisis de series temporales, el primer conjunto de modelos analiza datos históricos y hace uso de variables independientes para crear predicciones de mercado o clasificar el rendimiento de las acciones en categorías. Por otro lado, los modelos de análisis de series temporales usan los datos históricos para identificar tendencias, basados en los cuales crea futuras predicciones, por lo que el reconocimiento de patrones juega un rol crucial” [6]. Dos de los modelos mas conocidos dentro del análisis de series temporales son los modelos ARIMA y GARCH.

I-D. Deep Learning

Deep Learning (DL) se define como un subset dentro de *Machine Learning* (ML) que usa redes neuronales con muchas capas para modelar patrones complejos en los datos [6]. En cuanto a inversiones se refiere, técnicas de *Deep Learning* son usadas en predicción de activos en bolsa, análisis de datos no lineales, etc. Algunas de las técnicas presentes en *Deep-Learning* son ampliamente usadas en el mundo financiero, como por ejemplo las Redes Neuronales Recurrentes *Recurrent Neural Networks* (RNN) son un tipo de red neuronal, diseñada para procesar datos secuenciales manteniendo una memoria de entradas previas, las Redes Neuronales Convolucionales *Convolutional Neural Network*

(CNN) son arquitecturas usadas para procesar datos de tipo malla como imágenes y series temporales, *Long Short Term Memory* (LSTM) es una red RNN especializada diseñada para capturar dependencias de largo plazo en datos secuenciales, evadiendo el *gradient-vanishing-problem* o por ultimo *Gated Recurrent Unit* o GRU, las cuales son una versión simplificada de el modelo anteriormente mencionado que procesa datos secuenciales al mismo tiempo que logra reducir la complejidad computacional [6].

Estas técnicas tienden a superar a los métodos tradicionales en cuanto a precisión, sin embargo estas técnicas son susceptibles a la calidad de los datos con los que son entrenados o tienen problemas con la volatilidad del mercado (Ademas que su entrenamiento requiere mas tiempo). [4]

I-E. Transformer

El modelo *Transformer*, es una arquitectura de aprendizaje profundo cuyo diseño original buscaba lograr traducciones automáticas. Consiste en reemplazar las estructuras secuenciales recurrentes por un mecanismo de auto-atención que permite procesar de forma paralela todos los elementos de una secuencia y capturar relaciones de dependencia a largo plazo que puedan existir entre ellos [7].

Cabe recalcar que los *Transformers* no dependen del orden de entrada explícito, sino que incorpora información posicional a través de vectores de codificación, es gracias a eso y a la gran flexibilidad y escalabilidad que es una gran alternativa para modelos aplicados a series temporales financieras. La arquitectura original del modelo *Transformer* se pude ver en la Figura 1




Figura 2: Arquitectura de un Transformer propuesta por Vaswani et al, 2017

La arquitectura del modelo *Transformer* propuesta por Vaswani et.al fue adaptada para su uso en tareas de predicción básicas, con resultados deplorables dada la poca adaptabilidad del modelo a contextos volátiles y no estables [8]

II. ESTADO DEL ARTE

II-A. Arquitecturas Transformer enfocadas en predicción bursátil

Dada la misma naturaleza del mercado, la cantidad de modelos *Transformer*, en base al modelo original propuesto por Vaswani et al. [7] para predicción de activos se diversifico, con algunos modelos especializándose en mercados específicos u objetivos específicos, modificando de forma superficial mecanismos específicos, mientras que en algunos casos recurriendo a la implementación de modelos híbridos para la aplicación de dichas mejoras a entornos específicos [7] [9] [10]. Por ello, es valido construir una taxonomía *Transformer* revisadas separadas en 2 categorías:

II-B. Arquitecturas Transformer Evolucionadas

En esta categoría tenemos todas las arquitecturas que poseen alguna modificación arquitectónica de la estructura original del *Transformer* original de Vaswani et al. manteniendo la esencia del *Transformer* en si con ligeras modificaciones en como operan la atención o el flujo de datos para lograr la resolución de problemas.

Los autores Li et al. [11] proponen el modelo MASTER o *Market-Guided Stock Transformer*, diseñado específicamente para la predicción considerando correlaciones dinámicas entre diversas acciones. El modelo introduce dos innovaciones importantes: Minería de correlaciones momentáneas y *cross-time*, capturando relaciones entre acciones en distintos momentos, un mecanismo de *gating* guiado por el mercado, el cual selecciona automáticamente las características más relevantes según el estado del mercado. Evaluaciones realizadas sobre *datasets* como CSI300 y CSI800, usando métricas tanto de *ranking* como de portafolio en CSI300 mostraron que MASTER alcanzó un IC de 0.064 y RankIC de 0.076, superando a modelos anteriores como LSTM (IC 0.049, RankIC 0.051) o el modelo *Transformer* estándar (IC 0.047, RankIC 0.051), en métricas de portafolio, MASTER obtuvo un *Excess Annualized Return* o AR de 0.29 y un *Information Ratio* o IR de 2.3, frente a valores de AR e IR de 0.20 y 2.0 en LSTM, demostrando que MASTER es capaz de capturar correlaciones bursátiles dinámicas y una superioridad en métricas de rentabilidad ajustada por riesgo (construcción de un mejor portafolio), consolidándose como un avance relevante en *forecasting* financiero multiactivo.

Los autores Zhou et al [12] proponen la arquitectura *Informer*, el cua es un modelo basado en la arquitectura *Transformer* original para *Long Sequence Time-Series Forecasting* (LSTF). El modelo introduce tres innovaciones principales: *ProbSparse Self-Attention*, reduciendo la complejidad en tiempo y memoria, *Self-Attention Distilling* el cual da mayor atención a "atenciones dominantes", y un *decoder* generativo, capaz de producir secuencias largas en una sola operación, evitando

la acumulación de errores. Se hicieron evaluaciones sobre los *datasets* ETTh1, ETTh2, ETTm1, etc donde muestra mejoras frente a modelos anteriores tales como Reformer, LogTrans, etc con el *dataset* ETTh1 por ejemplo, con un horizonte de 24 pasos, el modleo Informer obtuvo un MSE de 0.098 y un MAE de 0.247, superando a ARIMA y LSTM, por lo que se una de sus fortalezas incluye una buena capacidad en horizontes largos, sin embargo sigue siendo computacionalmente mas costoso que enfoques lineales a pesar de *ProbSparse*.

Los autores Ji et al. proponen el modelo *Galformer* [8], diseñado con el propósito específico de predicción *multi-step* de índices bursátiles (CSI 300, SP500, Dow Jones y Nasdaq), introduciendo ademas un *decoder* generativo capaz de producir secuencias largas en una sola operación evitando acumulación de errores, también presenta una función de perdida híbrida, la cual combina MSE con precisión en la tendencia. El modelo fue comparado con el *Transformer* estándar (modificado para admitir series temporales), Informer y Autoformer. En el *dataset* del SP500 se reporto un ACC equivalente al 52.69 %, un RMSE de 37.88, un MAPE deL 0.78 %, un MAE de 28.93 y un R2 de 98.56 %, mientras que en el *dataset* de CSI300 el modelo alcanzo un ACC de 52.75 %, un RMSE de 62.14, un MAPE de 0.93 %, un MAE de 47.15 y un R2 de 95,23 %, presentando una mayor eficiencia en la predicción de secuencias largas así como sensibilidad a las tendencias del mercado, sin embargo es importante recalcar la complejidad del *decoder*, ademas el mismo articulo indica que el MSE puede ser bajo sin realmente capturar de forma correcta las subidas y bajadas de tendencia

Los autores Chen et al. [13] proponen el modelo *Pathformer*, diseñado para la predicción mediante la integración de múltiples escalas de resolución y distancia temporal introduciendo 2 inovaciones: un bloque *Transformer* multiescala que unifica la división de la serie en parches de diversos tamaños con un mecanismo de atención dual, ademas de un sistema de rutas adaptativas que ajusta dinámicamente el proceso de modelado. La arquitectura se organiza mediante el apilamiento de bloques multiescala adaptativos *AMS Blocks* incluyendo un *router* con descomposición de tendencia y estacionalidad para extraer patrones periódicos asi como tendencias

Este modelo emplea atención dual: una atención *intra-patch* para capturar detalles locales y una atención *inter-patch* para modelar correlaciones globales, finalmente, un agregador ponderado combina estas características multiescala antes de la predicción. Se realizaron evaluaciones en once *datasets* del mundo real, incluyendo ETT, Weather, Electricity y Traffic, donde Pathformer supero a modelos como PatchTST y NLinear

II-C. Arquitecturas Transformer Ensambladas

En esta categoria podemos encontrar arquitecturas *Transformer* que hacen uso de otras arquitecturas de *Deep Learning*

o que reemplazan alguno de sus mecanismos con alguna de dichas arquitecturas para la resolución de sus objetivos.

Los autores Zeng et al. [14] proponen el modelo *CNN and Transformer Based Time Series* o CTTS, diseñado para aprovechar las fortalezas de las CNN para capturar patrones locales y de las arquitecturas *Transformer* para modelar dependencias de largo plazo. Las evaluaciones se realizaron sobre precios minuto a minuto para el SP500 en el año 2019, se compararon los resultados con otros modelos como ARIMA, EMA o DeepAR, donde CTTS mostro mejoras frente a modelos anteriores, alcanzando una exactitud del 56.7%, frente a ARIMA con un 50.9%, EMA con un 53.2% o DeepAR con un 51.1% en la "tarea de 2 clases", al aplicar un umbral de confianza (75 percentil), la exactitud aumentó significativamente: 66.8% en 2-clases y 55.2% en 3-clases. por lo que entre las fortalezas de CTTS se aprecia una mejor capacidad de predicción en entornos financieros volátiles, sin embargo, al ser un híbrido posee mayor coste computacional.

Los autores Kabir et al. [9] proponen el modelo *LSTM-mTrans-MLP* el cual es un enfoque híbrido diseñado para mejorar la predicción de series temporales financieras mediante la integración de tres componentes complementarios, empezando con un bloque LSTM captura dependencias de corto y largo plazo, el cual genera un vector de características, este se introduce en un *Transformer* que emplea *multi-head attention*, conexiones residuales y una arquitectura simplificada sin *embeddings* ni decodificador, permitiendole concentrar la atención en las secciones más relevantes de la secuencia y mejorar la contextualización temporal, para al final, una red perceptron multicapa aprender relaciones no lineales complejas a partir de las representaciones atencionales, produciendo la estimación final del precio futuro. Se realizaron pruebas en múltiples activos financieros (Bitcoin, China Unicom, CSI 300, CSI 100, Shanghai Composite Index, Amazon y Google) donde mantuvo consistencia bajo condiciones de alta volatilidad como la pandemia de COVID-19 superando modelos estadísticos redes profundas convencionales en métricas como MSE, RMSE, MAE y MAPE dependiendo del *dataset* usado, por lo que sus fortalezas incluyen robustez, bajo número de parámetros y excelente capacidad de generalización.

Los autores Li et al. [15] proponen el modelo Stockformer, diseñado para *forecasting* financiero multivariado y lograr predecir el precio de un activo con horizonte de una hora, incorporando una innovación principal: Un diseño de *embedding* con 1D-CNN el cual busca extraer patrones temporales de cada activo. Recaltar también que hace uso de *ProbSparse Attention* así como el uso de *Self-Attention Distilling* para reducir la complejidad computacional (ambas tomadas de Informer). Se hicieron evaluaciones sobre datos horarios obtenidos de Polygon.io, Alpaca y Alpha Vantage, se aplicaron métricas específicas para trading (Stock Direction y Stock Tanh) para el calculo de rentabilidad. donde Stockformer alcanzó un

Profit Ratio de 1.7550 (valor específico de configuración: embedding size = 512, heads = 512), comparando ProbSparse Attention contra el *Transformer* con atención completa, se observo que *ProbSparse* generalizaba mejor con menor costo computacional, confirmando su capacidad de generalización, por lo que entre las fortalezas de Stockformer se puede apreciar una capacidad robusta para capturar dependencias multiactivo en horizontes horarios (algo poco común en esta área de investigación), sin embargo esta limitado por su propio horizonte corto y relaciones sectoriales del mercado.

Los autores Xu et al. [16] proponen el modelo HRFormer (Hybrid Relational Transformer), diseñada específicamente para predicción de tendencias bursátiles que busca capturar la naturaleza volátil y no estacionaria de los mercados, este modelo introduce 3 innovaciones: la Capa de Descomposición Multi-Componente que divide la serie en tendencia, ciclo y volatilidad, el Codificador Temporal por Componente (CTE) que procesa cada rama, y finalmente el mecanismo *Inter-Stock Correlation Attention* (ISCA), que utiliza una transposición de dimensiones para modelar las correlaciones espaciales entre diferentes acciones.

Se realizaron evaluaciones sobre los *datasets* NASDAQ100 y CSI300, donde HRFormer obtuvo un ACC del 54.91% superando a los modelos comparados y destacando su rentabilidad en mercados volátiles.

Los autores Sheng et al. [17] proponen el modelo LASSO NSAAutoformer, un modelo que integra análisis de texto para la creación de predicciones, introduce 3 innovaciones: LASSO para la selección de características críticas y mitigación de la multicolinealidad, el Análisis de Sentimiento Financiero extraído de noticias y comentarios para capturar sentimiento del mercado y el núcleo NSAAutoformer, el cual usa factores de de-estacionarización que ajustan desplazamientos en la distribución de los datos

Se realizaron evaluaciones sobre datos estructurados y no estructurados, incluyendo CSI 300, donde mostro mejoras en MAE, RMSE, MAPE y R^2 (26.97, 34.512, 0.007 y 0.98 respectivamente), señalan los autores la capacidad del modelo de capturar dinámicas diversas del mercado

III. TÉCNICAS A IMPLEMENTAR

La metodología de esta investigación busca usar un enfoque experimental orientado al desarrollo y comparativa mediante métricas de un subconjunto de las arquitecturas expuestas. De entre las arquitecturas revisadas se eligió las arquitecturas *CATS* y *FredFormer* debido a la similitud de objetivos así como uso de *datasets* similares. A continuación se describirán las técnicas elegidas así como las métricas de comparación.

III-A. CATS

Los autores Kim et al. [10] proponen el modelo CATS (*Cross-Attention-only Time Series Transformer*) una arquitectura la cual elimina la *self-attention* tradicional por completo y

emplea unicamente el mecanismo de atención cruzada (*Cross-Attention*), mejorando la predicción en horizontes largos. CATS introduce tambien las Consultas Dependientes del Horizonte (*Horizon-Dependant Queries*), donde cada paso futuro es representado por una consulta que atiende directamente al historial pasado, *Parameter Sharing Across Horizons* reutiliza las mismas capas de *embedding*, atención y proyección para todos los horizontes, permitiendo que el numero de parametros se mantenga constante incluso cuando el horizonte de predicción crece de manera significativa, ademas también introduce el *Query-Adaptive Masking* el cual genera mascarillas adaptativas evitando que todos los horizontes produzcan salidas similares

En la figura 3 se presenta la arquitectura para el modelo CATS propuesta por Kim et al.




Figura 3: Arquitectura del modelo CATS, propuesta por Kim et al. [10]

Se realizaron pruebas en los *datasets* Electricity, Weather, Traffic, ETTh1, ETTh2, ETTm1, ETTm2 y M4 y se comparo CATS con un gran numero de *baselines* usando un varios horizontes de predicción con una entrada de 96 secuencias de largo para horizontes largos para los *datasets* de ETT, Traffic, Electricity y Weather, comparándose con técnicas para predicción de series temporales largas, demostrando su superioridad ante las otras técnicas con mayor notoriedad en el *dataset* de Traffic, obteniendo el MSE y MAE mas bajos (0.421 y 0.270 respectivamente), ademas, al momento de probar para el *dataset* M4, para precondition de series de tiempo de termino corto, CATS obtuvo los mejores resultados en todas las métricas, resolviendo el problema de perdida de información temporal de una de las arquitecturas *Transformer* del estado del arte con atención completa, demostrando así en palabras de los autores la capacidad de CATS para capturar dependencias temporales de termino corto, proveyendo asi una eficiencia superior en tareas de *forecasting* en términos cortos.

Cabe notar un *time complexity* del *decoder* optimizado en comparacion a otras arquitecturas *Transformer* comparadas:

$$O(LT/P^2)$$

Figura 4: Complejidad del decoder del modelo CATS

Demostrada por los autores, dado que hace un uso mas eficiente en cuanto a memoria en GPU se refiere, solo siendo

superado por modelos que requieren un enorme numero de parámetros.

Para el entrenamiento de CATS se usaron 4 NVIDIA RTX 4090 24 GB GPU's con 2 Intel (R) Xeon(R) Gold 521R CPU's, cada una con 2.10 Ghz para todos los experimentos

III-B. Fredformer

Propuesto por Piao et al. [18], el modelo Fredformer (*Frequency Debaised Transformer*) es una arquitectura diseñada para mitigar el "sesgo de frecuencia inherente a las *Transformers* tradicionales, dicho sesgo provoca que el mecanismo de auto atención (*self-attention*) de prioridad a componentes de baja frecuencia (tendencias globales) sobre características de alta frecuencia, las cuales son cruciales para la precisión de un pronostico, operando sobre un *backbone DFT-a-IFT*, descomponiendo la serie temporal en coeficientes de frecuencia antes del procesamiento neuronal, Fredformer introduce 3 innovaciones fundamentales: el *Patching* de Bandas de Frecuencia el cual segmenta el espectro con el objetivo de gestionar sub frecuencias de manera independiente, la Normalización Independiente de Sub-Frecuencias, la cual proyecta las amplitudes en un rango de 0 a 1, eliminando disparidades proporcionales asegurando que el modelo le asigne la importancia equitativa a todos los componentes clave, por ultimo introduce la atención por canal, la cual se aplica dentro de cada sub-banda para capturar correlaciones entre variables sin que amplitudes dominantes lleguen a sesgar el aprendizaje.

En la figura 5 se presenta la arquitectura para el modelo Fredformer propuesta por Piao et al.




Figura 5: Arquitectura del modelo Fredformer, propuesta por Piao et al. [18]

Los autores también emplean una variante de la aproximación de NystromFormer para una versión mas ligera de Fredformer, la cual reduce la complejidad computacional a una escala lineal, resultando así en:

$$O\left(\frac{L}{P}C\right)$$

Figura 6: Complejidad computacional de la versión ligera de Fredformer

Para el Fredformer ligero, demostrando que es posible también tener eficiencia y precisión a pesar de usar atención completa.

Se realizaron pruebas sobre los datasets Electricity, Weather, Traffic, ECL, ETTh1, ETTh2, ETTm1, ETTm2 y Solar-Energy, en el caso de *forecasting* multivariado para longitudes de predicción de 96, 192, 336 y 720, Fredformer demostro un rendimiento mauor para los *datasets* ETTh, ECL, Weather y Solar Energy obteniendo los MSE y MAE menores en dichos *datasets* (0.175 y 0.269 para el caso de ECL por ejemplo) solo siendo superado en el caso del *dataset* de Traffic por la arquitectura *iTransformer*, ademas de que a través de visualizaciones mediante mapas de calor de Fourier, se confirmo que Fredformer logro una reducción uniforme del error Relativo (*Frequency Bias for Transformer*) en todo el espectro, capturando las características de alta frecuencia que otros modelos suelen pasar por alto.

Cabe recalcar que ambas arquitecturas aprecian la capacidad de generalidad, algo poco común en modelos *Transformer* actuales. Sin embargo la estrategia que aplican es opuesta entre ellas (Fredformer basa dicho en la frecuencia mientras que CATS propone la modificación del mecanismo de atención, alejándose de lo que Vaswani et al. propuso en su día.)

III-B1. Métricas: Para la evaluación se usaran métricas diseñadas para la medición del rendimiento de arquitecturas *Transformer* para el *dataset* M4: SMAPE, MASE y OWA

III-B1a. sMAPE: El error porcentual absoluto medio simétrico (*Symmetric Mean Absolute Percentage Error*) es una métrica la cual mide la magnitud promedio de los errores en porcentajes, normalizando por el promedio de los valores reales y predichos. evitando asi problemas de división por cero.

$$\text{sMAPE} = \frac{2}{n} \sum_{i=1}^n \frac{|y_i - \hat{y}_i|}{|y_i| + |\hat{y}_i|} \times 100$$

Figura 7: Fórmula para el sMAPE

Donde:

- n representa el número de muestras
- y_i es el valor real
- $\hat{y}_i$ es el valor prededido
- El resultado se expresa en porcentaje

III-B1b. MASE: El error absoluto medio escalado (*Mean Absolute Scaled Error*) es una métrica de precisión la cual busca normalizar el error absoluto medio frente a un mo-

delo de referencia, permitiendo comparaciones significativas entre series temporales de diferentes escalas y características.

$$\text{MASE} = \frac{\text{MAE}}{\text{MAE}_{\text{ref}}}$$

Figura 8: Fórmula para el MASE

Donde:

- $\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$ es el error absoluto medio del modelo
- $\text{MAE}_{\text{ref}} = \frac{1}{n} \sum_{i=1}^n |y_i - y_{i-m}|$ es el MAE del modelo de referencia
- m es la estacionalidad

III-B1c. OWA: El promedio ponderado general (*Overall Weighted Average*) es una métrica de síntesis que combina sMAPE y MASE en un único valor permitiendo un ranking único de modelos. Este es el indicador oficial de desempeño en M4.

$$\text{OWA} = \frac{1}{2} \left(\frac{\text{sMAPE}}{\text{sMAPE}_{\text{ref}}} + \frac{\text{MASE}}{\text{MASE}_{\text{ref}}} \right)$$

Figura 9: Fórmula para el OWA

Donde:

- sMAPE y MASE son los valores obtenidos por el modelo propuesto
- $\text{sMAPE}_{\text{ref}}$ y MASE_{ref} son los valores del modelo de referencia ref

III-B2. Datasets: El *dataset* usado para reproducir los resultados es el *dataset* M4 (Makridakis 4), un *benchmark* de *forecasting* para *Transformers*:

- M4 (benchmark de la competición Makridakis 2018), uno de los *datasets* mas usados en *forecasting*, contiene 100000 series temporales de diversas frecuencias.

Cabe mencionar también que los modelos estudiados usan ambos los *datasets* ETT, Weather, Electricity, Traffic y Solar-Energy, Fredformer no usa de forma nativa M4, sin embargo la misma naturaleza del modelo y del *dataset* permite su entrenamiento en este ultimo.

IV. EXPERIMENTOS

Se planteo el uso de las métricas oficiales para la evaluación del *benchmark* M4 (sMAPE, MASE, OWA) para asegurarse precisión y reproductibilidad específicamente en el caso de CATS, requiriendo una adaptación para el caso de *Fredformer* que no usa nativamente dicho *dataset*. Los experimentos originales del modelo CATS fueron hechos en 4 GPU's NVIDIA RTX 4090 24 con 2 Intel(R) Xeon(R) Gold 5218R CPUs @ 2.10 GHz para todos los casos, mientras que en el caso de *Fredformer* no se especifica en que ambientes se realizaron los experimentos. Las replicas de ambos trabajos se entrenaron en una GPU NVIDIA Tesla T4 16GB, en el entorno de Google Collab.

IV-A. Parámetros del entrenamiento

- Dataset: M4
- d_model : 64
- $d_layers/encoders$: 3
- d_ff : 256
- n_heads : 16 $patch_len$
- $stride$: $patch_len$
- $batch_size$: 32
- $loss$: SMAPE
- $learning_rate$: 0.001
- $train_epochs$: 30
- $patience$: 10
- $seed$: 2021

A pesar que la mayoría de hiperparámetros permanecen similares entre si, dada la misma naturaleza arquitectónica de los modelos fue necesario ajustar los siguientes hiperparámetros:

Parámetro	CATS	Fredformer
n_heads	16	8
dropout / fc_dropout	-	0.3
QAM_end	0.3	-
use_nys / individual	-	use_nys=0; individual=0

Cuadro I: Hiperparámetros ajustados a cada modelo *Transformer*

IV-B. Makridakis 4

Para la experimentación se utilizo el *dataset Makridakis 4* el cual es un *benchmark* de *forecasting* para *Transformers* para la competencia internacional de *forecasting* organizada por Spyros Makridakis en 2018, incluye la siguientes series temporales para cada subconjunto:

- *Yearly*: 23000
- *Quarterly*: 24000
- *Monthly*: 48000
- *Weekly*: 359
- *Daily*: 4227
- *Hourly*: 414

V. RESULTADOS

Los resultados muestran que ambos modelos tuvieron un rendimiento similar en cuanto a las métricas propuestas por el *benchmark*, con una ligera superioridad del modelo *Fredformer* respecto a CATS

Al momento de reproducir los resultados para el modelo *Transformer* CATS para el *dataset* M4 se obtuvieron resultados proximos a los reportados por los autores, las ligeras diferencias entre los resultados originales y los obtenidos pueden deberse a variaciones en las verisiones de las librerias utilizadas, los resultados son presentados en el Cuadro II

Para el modelo *Fredformer*, no usa de forma nativa el *dataset* M4 por lo que requirió una adaptación ligera del protocolo para su correcto funcionamiento y evaluación, los resultados de esta experimentación se pueden apreciar en el Cuadro III

Las Figuras 10, 11 y 12 presentan los promedios obtenidos mediante graficos de barras agrupadas

Subconjunto	SMAPE	MASE	OWA
Yearly	13.477	3.047	0.796
Quarterly	10.103	1.180	0.889
Monthly	12.840	0.954	0.894
Weekly	9.997	3.253	1.132
Daily	3.029	3.230	0.990
Hourly	18.225	3.470	1.220

Cuadro II: Resultados Promediados para el dataset M4 para el modelo CATS

Subconjunto	SMAPE	MASE	OWA
Yearly	13.349	2.998	0.786
Quarterly	9.997	1.163	0.878
Monthly	12.604	0.919	0.869
Weekly	9.587	2.729	1.015
Daily	3.046	3.215	0.991
Hourly	15.979	2.447	0.945

Cuadro III: Resultados Promediados para el dataset M4 para el modelo *Fredformer*




Figura 10: Comparación de los resultados para ambos modelos para SMAPE



Figura 11: Comparación de los resultados para ambos modelos para MASE




Figura 12: Comparación de los resultados para ambos modelos para OWA

Se puede apreciar que Fredformer supero a CATS en 5 de los 6 subconjuntos del benchmark, ademas que las mejoras varian hasta un maximo de 22.5 % en el caos de Hourly

Es importante notar los tiempos de entrenamiento que tomo cada modelo *Transformer* en promedio, el cual curiosamente llevo a Fredformer a posicionarse mejor en tiempo de entrenamiento que su contraparte por un ligero margen

CATS	Fredformer
22.5	21

Cuadro IV: Tiempo promedio de entrenamiento para ambos modelos en minutos

Para justificar los resultados obtenidos se debe de denotar que mientras que CATS opera dentro del dominio del tiempo, Fredformer transforma la serie al dominio de las frecuencias, abordando el problema del sesgo de frecuencia sin aprender de forma desproporcionada de componentes de baja frecuencia, lo que da una respuesta mas equilibrada a todas las componentes claves del espectro, resaltando en subconjuntos con periodicidades marcadas (*Hourly*, *Monthly* o *Quarterly*). solo siendo superado en el caso del subconjunto *Daily* por un margen mínimo.

VI. CONCLUSIONES

El uso de arquitecturas *Transformer* para la predicción de activos, las cuales usan en su mayoría Series Temporales para la construcción de dichas predicciones, ha demostrado un alto nivel de eficiencia y adaptabilidad en el ultimo lustro, Cabe recalcar los diversos modelos que han surgido en base a los primeros intentos mediante el uso de la arquitectura propuesta originalmente por Vaswani et al. hasta los diversos modelos especializados que se poseen y se usan de forma comercial, entre ellos se compararon y se evaluaron los modelos *Transformer* CATS y Fredformer.

En base a los resultados obtenidos de dicha evaluacion se puede determinar que el modelo Fredformer, trabajando en el dominio de las frecuencias, supera al modelo CATS en la mayoría de los subconjuntos, sugiriendo que las series temporales del benchmark M4 tienen una estructura periodica que Fredformer logra capturar de mejor manera mientras que CATS, operando solo en tiempo con *cross attention*, ve su capacidad limitada para separar dinámicas de largo y corto plazo.

Debe mencionarse también sobre la integración de arquitecturas *Transformer* en modelos con mayor alcance como son los *Foundation Models for Time Series* así como en otras arquitecturas que dependen de la arquitectura *Transformer* o sus derivaciones para la correcta construcción de predicción en la bolsa de valores. Sin embargo estos modelos presentan una complejidad mayor al uso de arquitecturas *Transformer* como parte principal de la arquitectura pero al igual que las muchas derivaciones, es solo un paso mas en la evolución del deseo humano de conocer el futuro y desde el presente hacerlo parte de si.

REFERENCIAS

- [1] G. E. Box, G. M. Jenkins, G. C. Reinsel, and G. M. Ljung, *Time series analysis: forecasting and control (Revised)*. John Wiley & Sons, 2015.
- [2] T. Bollerslev, "Generalized autoregressive conditional heteroskedasticity," *Journal of econometrics*, vol. 31, no. 3, pp. 307–327, 1986.
- [3] O. Shobayo, S. Adeyemi-Longe, O. Popoola, and O. Okoyeigbo, "A comparative analysis of machine learning and deep learning techniques for accurate market price forecasting," *Analytics*, vol. 4, no. 1, p. 5, 2025.
- [4] L. Su, X. Zuo, R. Li, X. Wang, H. Zhao, and B. Huang, "A systematic review for transformer-based long-term series forecasting," *Artificial Intelligence Review*, vol. 58, no. 3, p. 80, 2025.
- [5] Y. Liang, H. Wen, Y. Nie, Y. Jiang, M. Jin, D. Song, S. Pan, and Q. Wen, "Foundation models for time series analysis: A tutorial and survey," in *Proceedings of the 30th ACM SIGKDD conference on knowledge discovery and data mining*, 2024, pp. 6555–6565.
- [6] M. Saberironaghi, J. Ren, and A. Saberironaghi, "Stock market prediction using machine learning and deep learning techniques: A review," *AppliedMath*, vol. 5, no. 3, p. 76, 2025.
- [7] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, E. Kaiser, and I. Polosukhin, "Attention is all you need," *Advances in neural information processing systems*, vol. 30, 2017.
- [8] Y. Ji, Y. Luo, A. Lu, D. Xia, L. Yang, and A. Wee-Chung Liew, "Galformer: a transformer with generative decoding and a hybrid loss function for multi-step stock market index prediction," *Scientific Reports*, vol. 14, no. 1, p. 23762, 2024.
- [9] M. R. Kabir, D. Bhadra, M. Ridoy, and M. Milanova, "Lstm-transformer-based robust hybrid deep learning model for financial time series forecasting," *Sci*, vol. 7, no. 1, p. 7, 2025.
- [10] D. Kim, J. Park, J. Lee, and H. Kim, "Are self-attentions effective for time series forecasting?" *Advances in Neural Information Processing Systems*, vol. 37, pp. 114 180–114 209, 2024.
- [11] T. Li, Z. Liu, Y. Shen, X. Wang, H. Chen, and S. Huang, "Master: Market-guided stock transformer for stock price forecasting," in *Proceedings of the AAAI conference on artificial intelligence*, vol. 38, no. 1, 2024, pp. 162–170.
- [12] H. Zhou, S. Zhang, J. Peng, S. Zhang, J. Li, H. Xiong, and W. Zhang, "Informr: Beyond efficient transformer for long sequence time-series forecasting," in *Proceedings of the AAAI conference on artificial intelligence*, vol. 35, no. 12, 2021, pp. 11 106–11 115.
- [13] P. Chen, Y. Zhang, Y. Cheng, Y. Shu, Y. Wang, Q. Wen, B. Yang, and C. Guo, "Pathformer: Multi-scale transformers with adaptive pathways for time series forecasting," *arXiv preprint arXiv:2402.05956*, 2024.
- [14] Z. Zeng, R. Kaur, S. Siddagangappa, S. Rahimi, T. Balch, and M. Veloso, "Financial time series forecasting using cnn and transformer," *arXiv preprint arXiv:2304.04912*, 2023.
- [15] S. Li, Z. B. Schulwol, and R. Miikkulainen, "Transformer based time-series forecasting for stock," *arXiv preprint arXiv:2502.09625*, 2025.
- [16] H. Xu, H. Wan, Y. Wu, J. Zheng, and L. Xie, "Hrformer: A hybrid relational transformer for stock time series forecasting," *Electronics*, vol. 14, no. 22, p. 4459, 2025.
- [17] Z. Sheng, Q. Liu, Y. Hu, and H. Liu, "A multi-feature stock index forecasting approach based on lasso feature selection and non-stationary autoformer," *Electronics*, vol. 14, no. 10, p. 2059, 2025.
- [18] X. Piao, Z. Chen, T. Murayama, Y. Matsubara, and Y. Sakurai, "Fredformer: Frequency debiased transformer for time series forecasting," in *Proceedings of the 30th ACM SIGKDD conference on knowledge discovery and data mining*, 2024, pp. 2400–2410.

Taxonomía	Nombre	Autores	Año	Objetivo	Datasets usados	Resultados
Arquitecturas Transformer Evolucionadas	Informer	Zhou et al.	2021	Mejorar LSTF mediante ProbSparse Self-Attention, Self-Attention Distilling y decoder generativo.	ETTh1, ETTh2, ETTm1, etc.	ETTh1 (horizonte 24): MSE: 0.098; MAE: 0.247.
	MASTER	Li et al.	2024	Capturar correlaciones dinámicas entre acciones mediante minería de correlaciones momentáneas y cross-time, con gating guiado por el mercado.	CSI300, CSI800.	IC: 0.064; RankIC: 0.076; AR: 0.29; IR: 2.3.
	Galformer	Ji et al.	2024	Predicción multi-step de índices bursátiles con decoder generativo y función de pérdida híbrida (MSE + tendencia).	CSI300, S&P500, Dow Jones, Nasdaq.	CSI300: ACC: 52.75 %, RMSE: 62.14, MAPE: 0.93 %, MAE: 47.25, R ² : 95.23 %; S&P500: ACC: 52.69 %, RMSE: 37.88, MAPE: 0.78 %, MAE: 28.93, R ² : 98.56 %.
	Pathformer	Chen et al.	2024	Forecasting multivariado de series temporales con arquitectura Transformer multi-escala, rutas adaptativas y mecanismo de doble atención.	ETT (ETTh1, ETTh2, ETTm1, ETTm2), Weather, Electricity, Traffic, ILI, Cloud Cluster (A, B, C).	Reducción de MSE: 8.1 % vs PatchTST; reducción de MAE: 6.4 %. Mejora sustancial frente a Pyraformer y Scaleformer.
	CATS	Kim et al.	2024	Eliminar la self-attention tradicional y emplear solo cross-attention para mejorar predicción en horizontes largos.	Electricity, Weather, Traffic, ETTh1, ETTh2, ETTm1, ETTm2, M4.	MSE: 0.149–0.342; MAE: 0.207–0.341 [18].
	Fredformer	Piao et al. [18]	2024	Mitigar el "sesgo de frecuencia" en LSTF mediante un backbone DFT-a-IDFT, patching de bandas de frecuencia y normalización independiente de sub-frecuencias.	Weather, Electricity, Traffic, Solar-Energy, ETT (ETTh1, ETTh2, ETTm1, ETTm2).	MSE: 0.175–0.435; MAE: 0.261–0.426.
Arquitecturas Transformer Ensambladas	CTTS	Zeng et al.	2023	Combinar CNN y Transformer para capturar patrones locales y dependencias de largo plazo en predicción de dirección de precios.	SP500 (datos minuto a minuto, 2019).	Exactitud: 56.7 % (2 clases); ARIMA: 50.9 %, EMA: 53.2 %; con umbral 75 percentil: 66.8 % (2 clases).
	LSTM-mTrans-MLP	Kabir et al.	2025	Integrar LSTM, Transformer simplificado y MLP para robustez en mercados volátiles.	Bitcoin, China Unicom, CSI300, CSI100, Shanghai Composite, Amazon, Google.	MSE: 0.0003–0.0005; RMSE: 0.016–0.021; MAE: 0.012–0.017; MAPE: 1.7 %.
	Stockformer	Li et al.	2025	Forecasting financiero multivariado usando embedding ID-CNN y técnicas de Informer (ProbSparse, Self-Attention Distilling).	Polygon.io, Alpaca, Alpha Vantage.	Profit Ratio: 1.7550 (configuración embedding size = 512, heads = 512) [29].
	HRFormer	Xu et al. [16]	2025	Predicir tendencias bursátiles mediante descomposición en tendencia, ciclo (Fourier) y volatilidad (LSTM), con atención inter-stock.	NASDAQ100, CSI300.	NASDAQ100: ACC: 54.91 %, Sharpe Ratio: 1.5354. CSI300: ACC: 52.61 %, Sharpe Ratio: 0.5398.
	LASSO-NSAautoformer	Sheng et al. [17]	2025	Marco híbrido que integra selección de características LASSO, análisis de sentimiento y núcleo NSAautoformer para series no estacionarias.	SSECI, SZSECI, GEI, CSI 300.	CSI 300: MAE: 26.97, RMSE: 34.512, MAPE: 0.007, R ² : 0.98.

Cuadro V: Taxonomía de arquitecturas *Transformer* para predicción financiera y de propósito general mediante el uso de series temporales basadas en su arquitectura.